

5a uloha

Vytvorili sme model MLP , ktorý sa naučil klasifikovať 3D body podľa súradníc x, y, z do 5 tried. Dáta sme normalizovali a rozdelili 80/20, rozdelili na tréningové a testovacie, trénovali model a vyhodnotili jeho presnosť. Vygenerovali sme grafy (strata, 3D rozloženie bodov, maticu zámeny) a otestovali sme nové body. MLP (3 vstupy – 14 neurónov – 5 výstupov), ReLU, Dropout(0.15), CrossEntropyLoss, optimalizácia Adam, 600 epôch.

	x	y	z	label
0	0.494408	0.247818	0.580521	1
1	0.288303	0.255194	0.704870	1
2	0.270189	0.545847	0.798475	1
3	0.700791	0.072356	0.799623	1
4	0.501954	0.174893	0.935588	1

Epócha [0/600], Strata: 1.6406

Epócha [100/600], Strata: 0.6587

Epócha [200/600], Strata: 0.3605

Epócha [300/600], Strata: 0.3130

Epócha [400/600], Strata: 0.2058

Epócha [500/600], Strata: 0.1799

Presnosť na trénovaní: 97.00%

Presnosť na testovaní: 96.00%

Predikcie pre nové body:

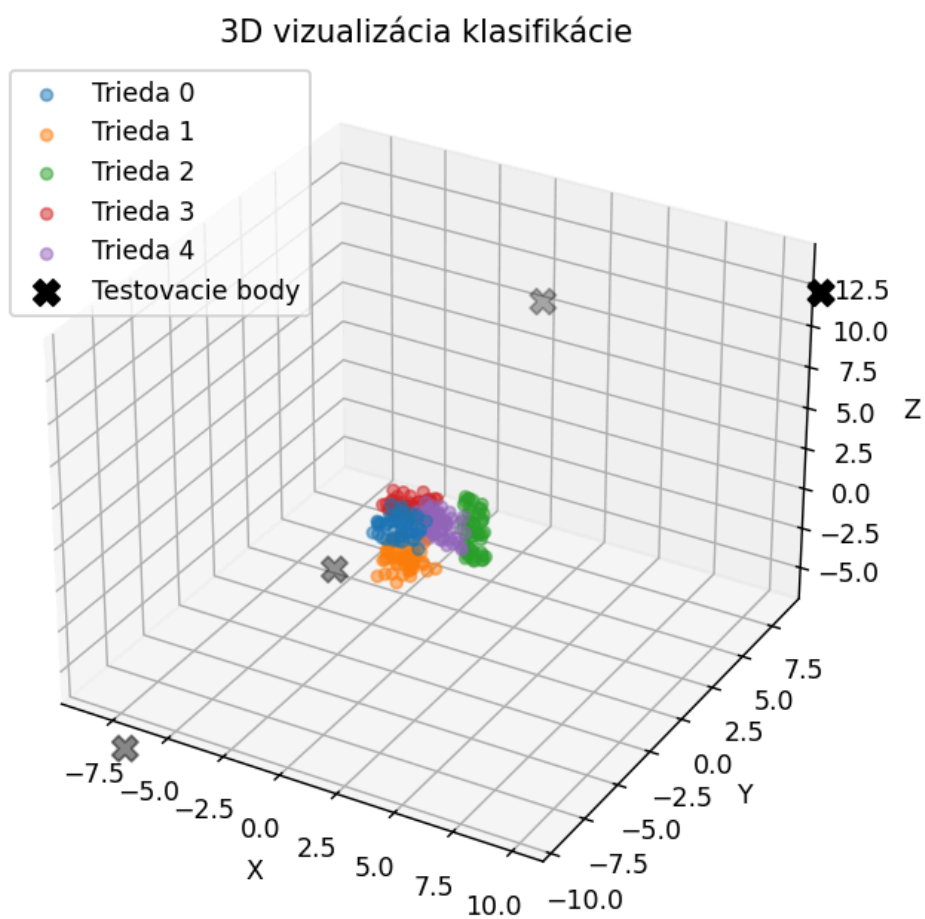
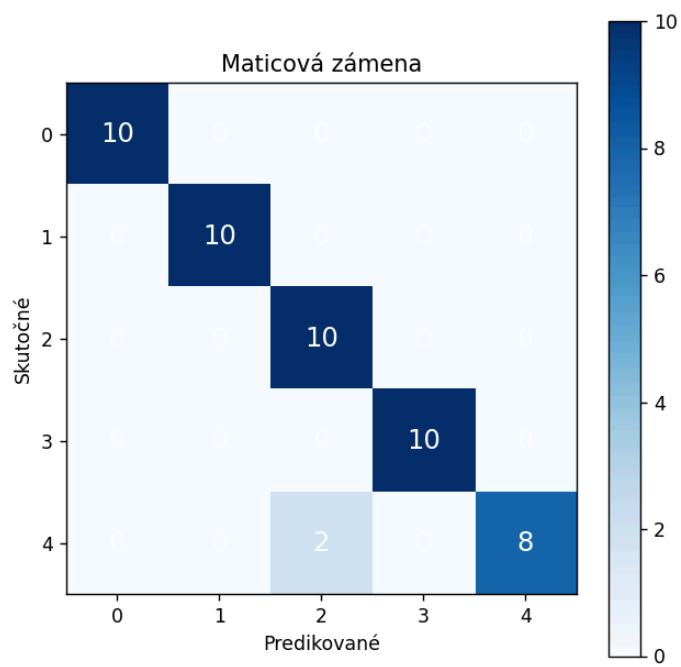
Bod 1: Trieda 2

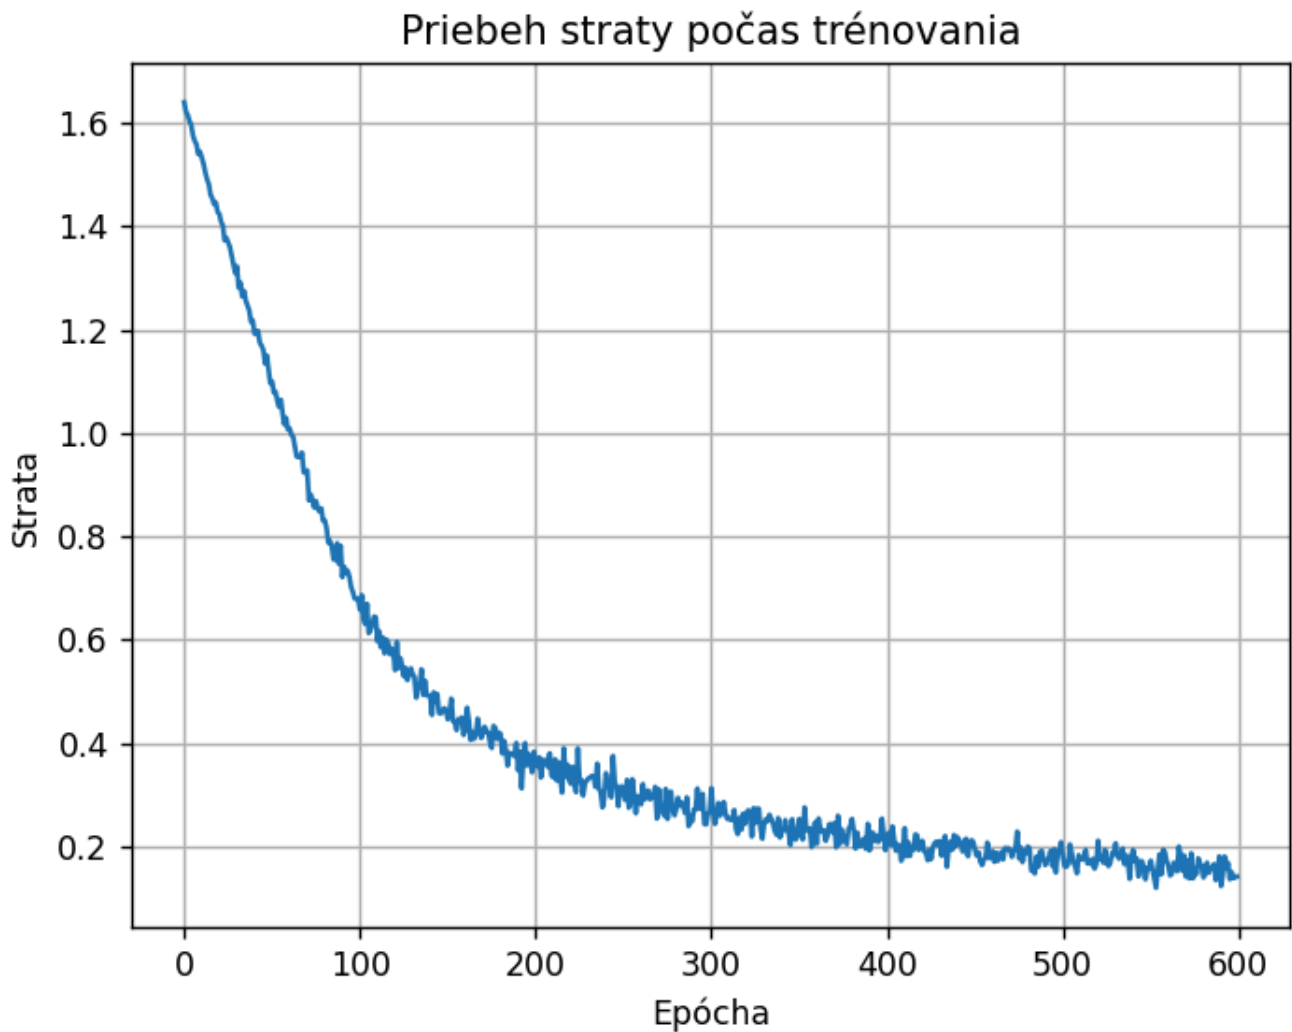
Bod 2: Trieda 2

Bod 3: Trieda 1

Bod 4: Trieda 2

Bod 5: Trieda 1

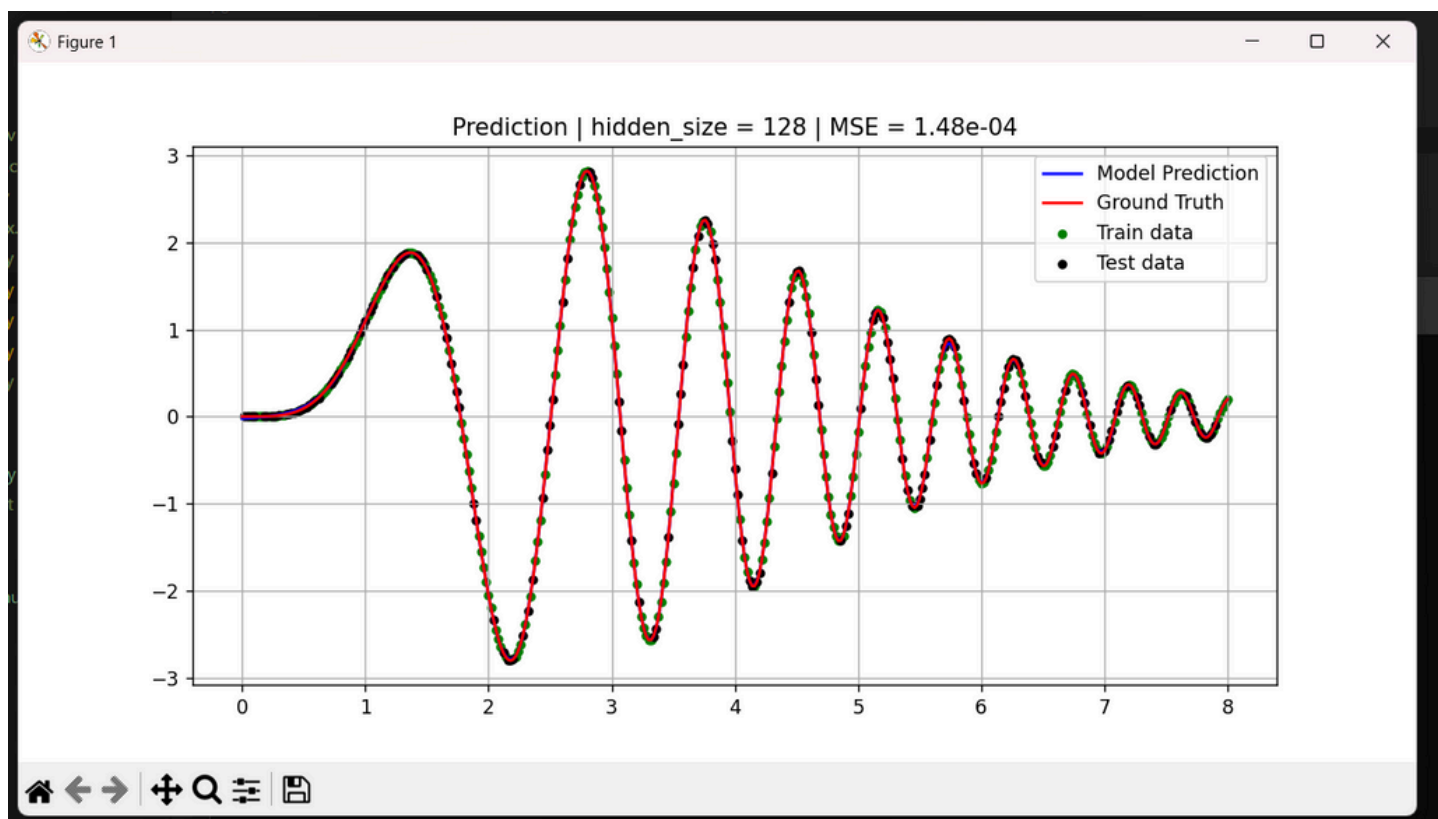
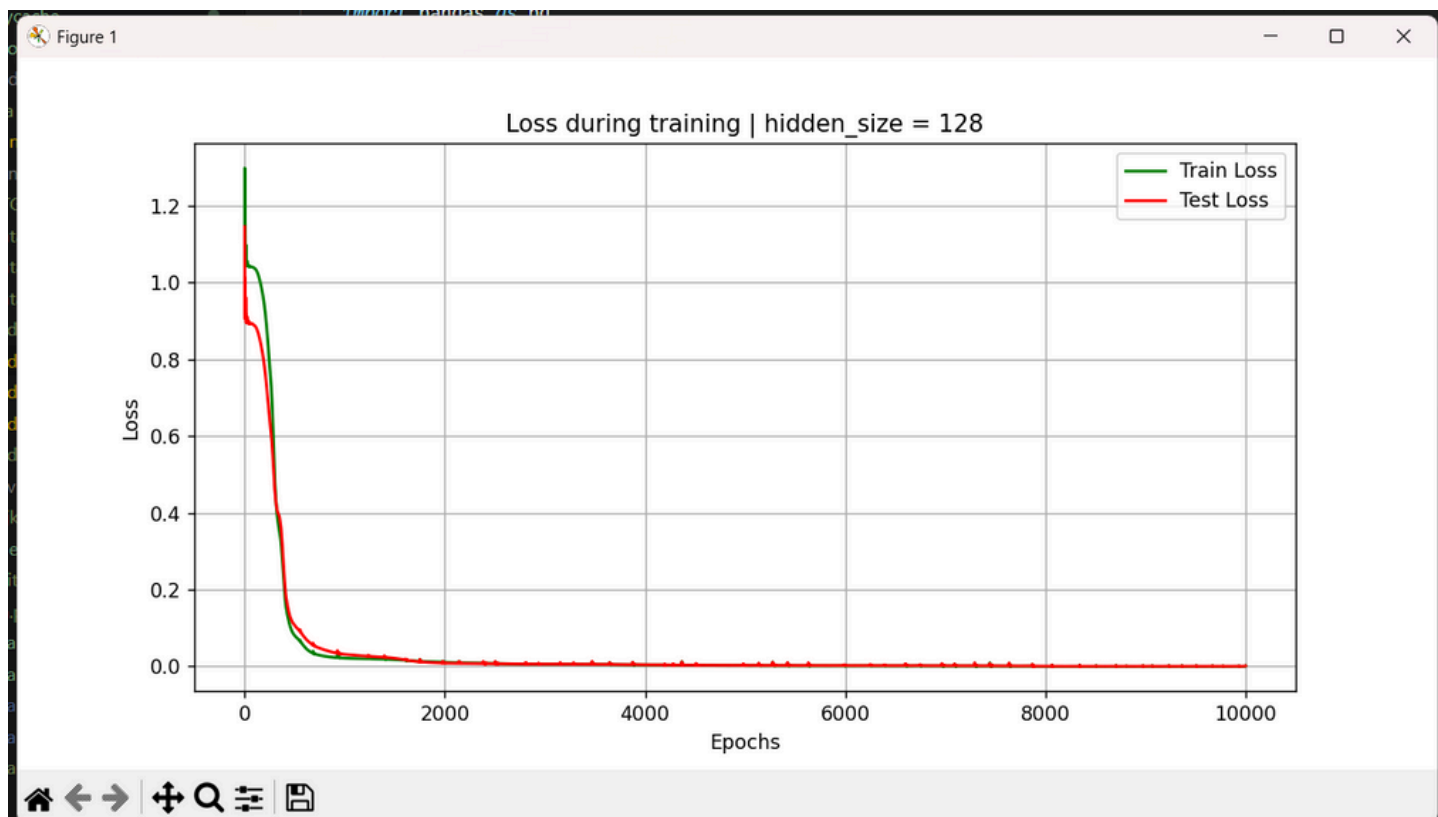




5b uloha

Trénovali sme regresný neurónový model (MLP) na predpovedanie výstupu y na základe vstupu x pomocou rôznych počtov skrytých neurónov (32, 64, 128). Porovnali sme výkonnosť modelov pomocou grafov a metrík (SSE, MSE, MAE). Mame jeden vstup a jeden výstup. Dáta sme rozdelili pomocou indexového súboru datafunindx.cs

```
Epoch 7501/10000, Train Loss: 0.000628, Test Loss: 0.001375
Epoch 8001/10000, Train Loss: 0.000145, Test Loss: 0.000399
Epoch 8501/10000, Train Loss: 0.000039, Test Loss: 0.000161
Epoch 9001/10000, Train Loss: 0.000130, Test Loss: 0.000279
Epoch 9501/10000, Train Loss: 0.000024, Test Loss: 0.000115
```



6 uloha

Trénovali sme tri rôzne MLP architektúry na rozpoznávanie CTG tried: Normálny, Podozrivý, Patologický. Vstup : 25 číselných znakov, výstup: trieda (0 = normálny, 1 = podozrivý, 2 = patologický),

```
Výsledky pre model: MLP_32
Trénovacia presnosť: min=0.9529, max=0.9624, priemer=0.9595
Testovacia presnosť: min=0.9060, max=0.9271, priemer=0.9199
Testovacia presnosť je nižšia ako 92%!
```

```
Výsledky pre model: MLP_64_32
Trénovacia presnosť: min=0.9945, max=0.9984, priemer=0.9959
Testovacia presnosť: min=0.9060, max=0.9389, priemer=0.9243
Testovacia presnosť spĺňa požiadavku (>92%)
```

```
Výsledky pre model: MLP_128_64_32
Trénovacia presnosť: min=0.9906, max=0.9976, priemer=0.9956
Testovacia presnosť: min=0.9013, max=0.9354, priemer=0.9210
Testovacia presnosť spĺňa požiadavku (>92%)
```


Porovnanie všetkých MLP modelov v percentách:

MLP_32	Train: 95.95%	Test: 91.99%
MLP_64_32	Train: 99.59%	Test: 92.43%
MLP_128_64_32	Train: 99.56%	Test: 92.10%


Testovanie vzoriek (1 z každej triedy):

Skutočný: 0, Predikovaný: 0
Skutočný: 1, Predikovaný: 1
Skutočný: 2, Predikovaný: 2


Confusion Matrix - MLP_32




Loss Curve - MLP_32



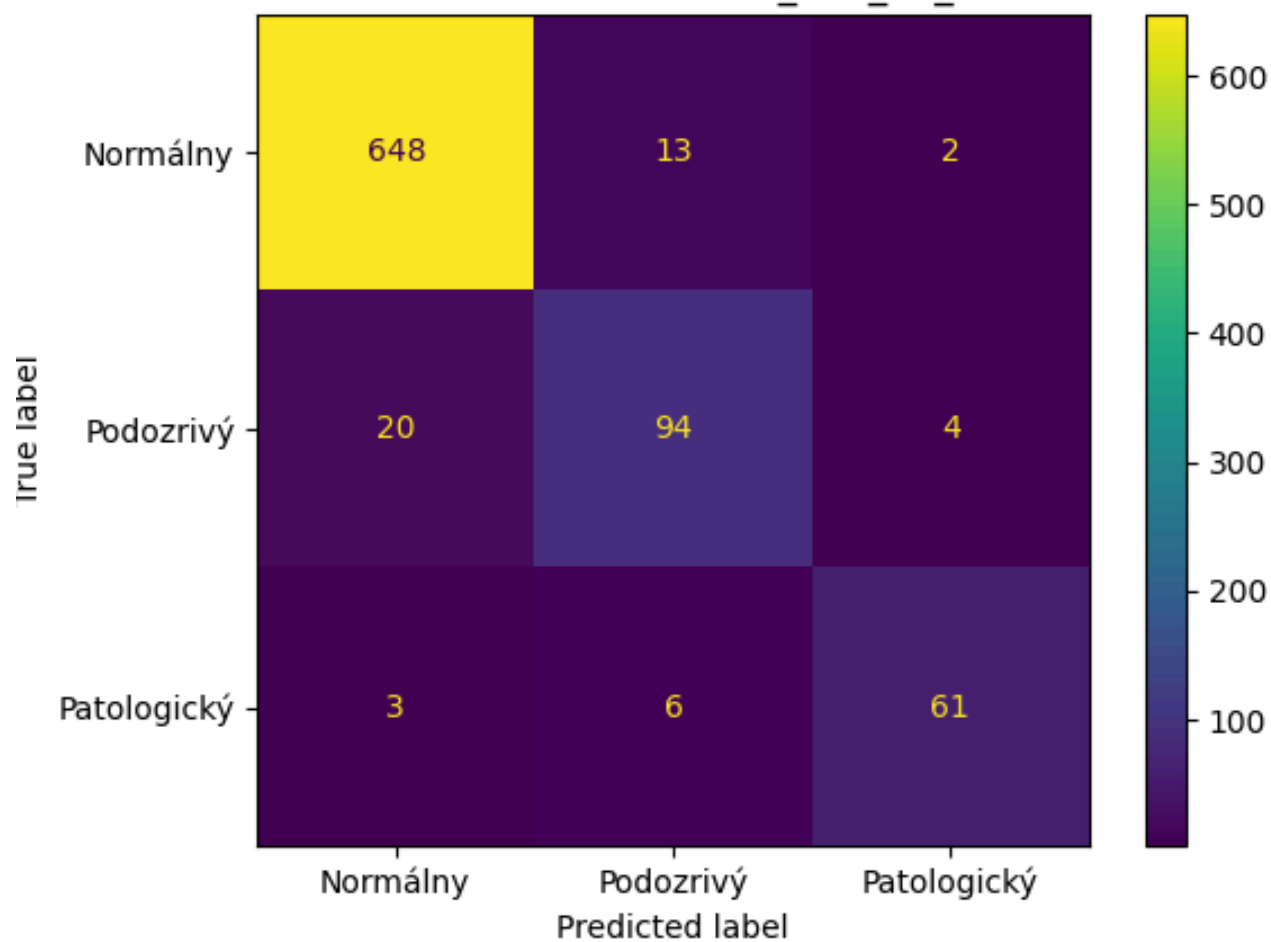
Confusion Matrix - MLP_64_32




Loss Curve - MLP_64_32



Confusion Matrix - MLP_128_64_32





7 uloha

Trénovali sme MLP model na rozpoznávanie ručne písaných číslíc (0–9) z datasetu MNIST. Tréning prebehol 5-krát, vždy s vyhodnotením presnosti a výberom najlepšieho modelu. Zobrazili sme konfúznú maticu a predikcie pre jednu vzorku z každej číslice. Vstup : 28×28 pixelov, výstup: číslo od 0 do 9 .

Presnosti modelu: zobrazili sa minimálna, maximálna a priemerná presnosť zo všetkých 5 tréningov. Konfúzna matica: ukazuje chyby v klasifikácii. Vizualizácia predikcie: pre každú číslicu bola zobrazená jedna vzorka s predikciou modelu.

Tréning 1/5...
Presnosť: 95.92%

Tréning 2/5...
Presnosť: 96.45%

Tréning 3/5...
Presnosť: 96.06%

Tréning 4/5...
Presnosť: 96.52%

Tréning 5/5...
Presnosť: 96.47%

🇸🇰 Presnosti:

Min: 95.92%

Max: 96.52%

Priemer: 96.29%

🔵 Predikcia jednej vzorky z každej číslice:

Číslo: 8, Predikované: 8

Číslo: 4, Predikované: 4

Číslo: 6, Predikované: 6

Číslo: 5, Predikované: 5

Číslo: 0, Predikované: 0

Číslo: 2, Predikované: 2


Číslo: 1, Predikované: 1

Číslo: 3, Predikované: 3

Číslo: 7, Predikované: 7

Číslo: 9, Predikované: 4


Konfúzna matica (najlepší model)




Číslo: 8 → Predikcia: 8



Číslo: 4 → Predikcia: 4



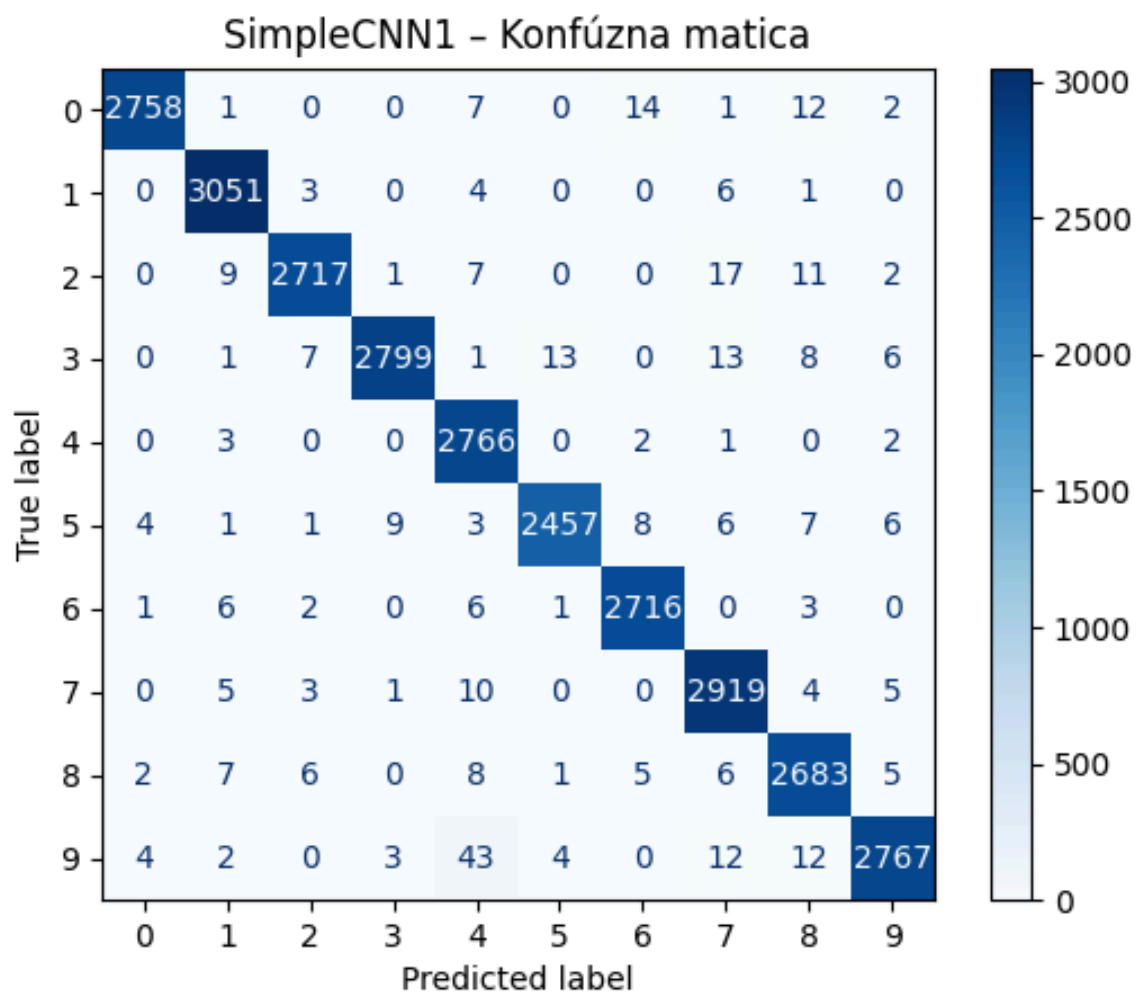
Číslo: 6 → Predikcia: 6



8 uloha


ulohou bolo porovnávať tri modely na klasifikáciu čísl z MNIST: dve konvolučné siete (SimpleCNN1, SimpleCNN2) a jednu MLP sieť. Dáta sú normalizované a náhodne rozdelené (60 % tréning, 40 % testovanie). Každý model sa trénuje 5krát, sleduje sa presnosť a vykresľuje sa konfúzna matica pre prvý pokus. Výsledkom je porovnanie presnosti jednotlivých architektúr.

```
Testujem SimpleCNN1
[SimpleCNN1] Epoch 1/5, Loss: 0.1877
[SimpleCNN1] Epoch 2/5, Loss: 0.0549
[SimpleCNN1] Epoch 3/5, Loss: 0.0346
[SimpleCNN1] Epoch 4/5, Loss: 0.0250
[SimpleCNN1] Epoch 5/5, Loss: 0.0199
```



```
Testujem SimpleCNN2
[SimpleCNN2] Epoch 1/5, Loss: 0.2087
[SimpleCNN2] Epoch 2/5, Loss: 0.0506
[SimpleCNN2] Epoch 3/5, Loss: 0.0336
[SimpleCNN2] Epoch 4/5, Loss: 0.0243
[SimpleCNN2] Epoch 5/5, Loss: 0.0201
```


SimpleCNN2 – Konfúzna matica



Testujem SimpleCNN1


```
[SimpleCNN1] Epoch 1/5, Loss: 0.1877
[SimpleCNN1] Epoch 2/5, Loss: 0.0549
[SimpleCNN1] Epoch 3/5, Loss: 0.0346
[SimpleCNN1] Epoch 4/5, Loss: 0.0250
[SimpleCNN1] Epoch 5/5, Loss: 0.0199
[SimpleCNN1] Epoch 1/5, Loss: 0.1966
[SimpleCNN1] Epoch 2/5, Loss: 0.0513
[SimpleCNN1] Epoch 3/5, Loss: 0.0357
[SimpleCNN1] Epoch 4/5, Loss: 0.0261
[SimpleCNN1] Epoch 5/5, Loss: 0.0210
[SimpleCNN1] Epoch 1/5, Loss: 0.1920
[SimpleCNN1] Epoch 2/5, Loss: 0.0502
[SimpleCNN1] Epoch 3/5, Loss: 0.0348
[SimpleCNN1] Epoch 4/5, Loss: 0.0240
[SimpleCNN1] Epoch 5/5, Loss: 0.0192
[SimpleCNN1] Epoch 1/5, Loss: 0.1947
[SimpleCNN1] Epoch 2/5, Loss: 0.0524
[SimpleCNN1] Epoch 3/5, Loss: 0.0361
[SimpleCNN1] Epoch 4/5, Loss: 0.0258
[SimpleCNN1] Epoch 5/5, Loss: 0.0200
[SimpleCNN1] Epoch 1/5, Loss: 0.2007
[SimpleCNN1] Epoch 2/5, Loss: 0.0543
[SimpleCNN1] Epoch 3/5, Loss: 0.0364
[SimpleCNN1] Epoch 4/5, Loss: 0.0266
[SimpleCNN1] Epoch 5/5, Loss: 0.0210
```

SimpleCNN1 – Min: 98.47%, Max: 98.95%, Priemer: 98.73%, Std: 0.16%

Testujem SimpleCNN2

```
[SimpleCNN2] Epoch 1/5, Loss: 0.2087
[SimpleCNN2] Epoch 2/5, Loss: 0.0506
[SimpleCNN2] Epoch 3/5, Loss: 0.0336
[SimpleCNN2] Epoch 4/5, Loss: 0.0243
[SimpleCNN2] Epoch 5/5, Loss: 0.0201
[SimpleCNN2] Epoch 1/5, Loss: 0.2076
[SimpleCNN2] Epoch 2/5, Loss: 0.0514
[SimpleCNN2] Epoch 3/5, Loss: 0.0370
[SimpleCNN2] Epoch 4/5, Loss: 0.0266
[SimpleCNN2] Epoch 5/5, Loss: 0.0224
[SimpleCNN2] Epoch 1/5, Loss: 0.2015
[SimpleCNN2] Epoch 2/5, Loss: 0.0507
[SimpleCNN2] Epoch 3/5, Loss: 0.0354
[SimpleCNN2] Epoch 4/5, Loss: 0.0262
[SimpleCNN2] Epoch 5/5, Loss: 0.0204
[SimpleCNN2] Epoch 1/5, Loss: 0.1956
[SimpleCNN2] Epoch 2/5, Loss: 0.0518
[SimpleCNN2] Epoch 3/5, Loss: 0.0350
[SimpleCNN2] Epoch 4/5, Loss: 0.0247
[SimpleCNN2] Epoch 5/5, Loss: 0.0225
[SimpleCNN2] Epoch 1/5, Loss: 0.2102
[SimpleCNN2] Epoch 2/5, Loss: 0.0561
[SimpleCNN2] Epoch 3/5, Loss: 0.0399
[SimpleCNN2] Epoch 4/5, Loss: 0.0285
[SimpleCNN2] Epoch 5/5, Loss: 0.0219
SimpleCNN2 - Min: 98.64%, Max: 98.86%, Priemer: 98.75%, Std: 0.09%
```

SimpleCNN2 - Konfúzna matica



```

Model: SimpleCNN2
[SimpleCNN2] Epoch 1/5, Loss: 0.2123
[SimpleCNN2] Epoch 2/5, Loss: 0.0515
[SimpleCNN2] Epoch 3/5, Loss: 0.0361
[SimpleCNN2] Epoch 4/5, Loss: 0.0263
[SimpleCNN2] Epoch 5/5, Loss: 0.0238
[SimpleCNN2] Epoch 1/5, Loss: 0.2168
[SimpleCNN2] Epoch 2/5, Loss: 0.0520
[SimpleCNN2] Epoch 3/5, Loss: 0.0353
[SimpleCNN2] Epoch 4/5, Loss: 0.0273
[SimpleCNN2] Epoch 5/5, Loss: 0.0212
[SimpleCNN2] Epoch 1/5, Loss: 0.2160
[SimpleCNN2] Epoch 2/5, Loss: 0.0506
[SimpleCNN2] Epoch 3/5, Loss: 0.0341
[SimpleCNN2] Epoch 4/5, Loss: 0.0269
[SimpleCNN2] Epoch 5/5, Loss: 0.0201
[SimpleCNN2] Epoch 1/5, Loss: 0.1949
[SimpleCNN2] Epoch 2/5, Loss: 0.0490
[SimpleCNN2] Epoch 3/5, Loss: 0.0334
[SimpleCNN2] Epoch 4/5, Loss: 0.0259
[SimpleCNN2] Epoch 5/5, Loss: 0.0217
[SimpleCNN2] Epoch 1/5, Loss: 0.2000
[SimpleCNN2] Epoch 2/5, Loss: 0.0477
[SimpleCNN2] Epoch 3/5, Loss: 0.0355
[SimpleCNN2] Epoch 4/5, Loss: 0.0259
[SimpleCNN2] Epoch 5/5, Loss: 0.0228
SimpleCNN2 - Min: 98.46%, Max: 98.95%, Priemer: 98.77%, Std: 0.21%

```

